

Instituto Tecnológico de Estudios Superiores de Monterrey
Campus Estado de México

Inteligencia artificial avanzada para la ciencia de datos

Momento de Retroalimentación: Módulo 2 Análisis y Reporte sobre el desempeño del modelo.
(Portafolio Análisis)

Reporte de Implementación: Random Forest regularizado con uso de framework

David Tinoco Romero - A01801491

Reporte de Implementación: Random Forest Base vs Regularizado con el uso Framework

Repositorio: [TC3009C---Momento-de-Retroalimentaci-n-/Modulo%20II](#)

I. Definición del Objetivo

El modelo será capaz de predecir si una canción será saltada, **y = skipped**, basándose en el contexto temporal de la reproducción (*hour, day_of_week*), el entorno tecnológico (*platform_ios, platform_osx*), la motivación de inicio (*reason_start_**) y el nivel de preferencia hacia el artista (*artist_frequency**).

II. Dataset

El algoritmo se alimentó con el historial de reproducción de Spotify del año 2026, el cual consta inicialmente de 10,589 registros.

Para garantizar que el modelo realmente aprenda a predecir y no se limite a hacer trampa, se realizó una limpieza estricta de las variables:

- **Para evitar Fuga de Datos (Data Leakage):** Se eliminaron variables como el tiempo reproducido (*ms_played*) y el motivo por el que terminó la canción (*reason_end*).
 - Incluirlos le habría dado al algoritmo la respuesta de si la canción fue saltada antes de hacer la predicción.
- **Para eliminar ruido y datos inútiles:** Se quitaron columnas como *incognito_mode* y *shuffle* porque casi todos sus valores eran exactamente iguales (ceros) y no aportaban capacidad predictiva. También se borró la basura del dataset, como direcciones IP y registros de audiolibros que alteraban el conteo de canciones.

La separación de datos se hizo de manera estratificada, dividiendo el dataset en 8,471 muestras para el conjunto de entrenamiento y 2,118 muestras para el conjunto de prueba. Se forzó al sistema a mantener el mismo porcentaje de canciones skipped en ambos grupos (18.53%), asegurando así una evaluación justa frente al desbalance natural de los datos

III. Arquitectura y Configuración de los Modelos Predictivos

III.1 El Modelo Base: Un Random Forest sin Restricciones

El primer artefacto predictivo, *rf_base*, tiene los hiperparametros seleccionados en la anterior entrega: cien estimadores (*n_estimators=100*), una profundidad máxima de cuarenta niveles (*max_depth=40*) y un umbral mínimo de división de apenas dos observaciones por nodo (*min_samples_split=2*). El modelo base funciona, en este sentido, como control experimental: la evidencia empírica de lo que ocurre cuando se le permite al Random Forest ejercer su voracidad estructural sin ninguna forma de contención.

* *artist_frequency* := Se utilizó frequency encoding mencionado en sección II y se puede acceder al map de este en [data\mapeo_artistas.json](#)

III.3 El Modelo Regularizado: Praxis de Contención Post-Búsqueda

El segundo artefacto, `rf_reg`, no surge de la intuición, sino como producto directo de un proceso de búsqueda de hiper parámetros en dos fases —exploración estocástica vía `RandomizedSearchCV` seguida de refinamiento exhaustivo vía `GridSearchCV`— orientado explícitamente a maximizar el recall de la clase minoritaria. La configuración resultante impone una contención múltiple: la profundidad máxima se reduce drásticamente a cuatro niveles:

- (`max_depth=4`), el umbral de división se eleva a siete observaciones
- (`min_samples_split=7`), el número de estimadores se reduce a setenta y cinco
- (`n_estimators=75`)
- y el criterio de impureza se desplaza del índice Gini hacia la entropía (`criterion='entropy'`), una medida basada en la ganancia de información.

A esta arquitectura se suma una decisión estructural adicional, ausente en el modelo base: la ponderación balanceada de clases (`class_weight="balanced"`), incorporada internamente en la clase `SpotifyRandomForest`, mediante la cual el algoritmo penaliza con mayor severidad los errores cometidos sobre la clase minoritaria durante el propio proceso de entrenamiento, compensando así el desbalance natural del 81.47% frente al 18.53% entre las clases "escuchado" y "salto". Se trata, en conjunto, de una arquitectura deliberadamente empobrecida en su capacidad de memorización, pero enriquecida en su sensibilidad hacia el fenómeno estadísticamente minoritario.

Este proceso y los resultados se explican más a fondo en [IV.4 Búsqueda de Hiper Parámetros](#)

IV. Análisis de Resultados y Evaluación de las predicciones

IV.1 Diagnóstico del Sesgo y la Varianza en el Modelo Primigenio

El modelo base, entregado a su propia voracidad estructural sin restricción alguna, revela un desempeño estadísticamente inequívoco. Con una exactitud del 93.83% sobre el conjunto de entrenamiento frente a un 78.10% sobre el conjunto de validación, se hace patente que el **s sesgo (bias) del modelo base es bajo**: el algoritmo posee capacidad más que suficiente para capturar —e incluso sobre-capturar— la complejidad funcional subyacente entre las variables contextuales (`hour`, `day_of_week`, `platform_`, `reason_start_`, `artist_frequency*`) y la variable objetivo `skipped`. Un modelo con sesgo alto jamás alcanzaría un 93.83% de ajuste sobre sus propios datos de entrenamiento; la hipótesis que construye el Random Forest sin restricciones es, en este sentido, lo suficientemente flexible como para no simplificar de más la realidad que observa.

Sin embargo, esta misma flexibilidad es la que condena al modelo a una **varianza alta**. La **brecha de 15.73pp** entre el desempeño en entrenamiento (**93.83%**) y en validación (**78.10%**) no es un margen de error tolerable: es la evidencia numérica de que el algoritmo dejó de

* `artist_frequency` := Se utilizó frequency encoding mencionado en sección II y se puede acceder al map de este en [data\mapeo_artistas.json](#)

aprender la *función generadora* del fenómeno "salto" para dedicarse, en cambio, a memorizar el ruido, las coincidencias, los artefactos irrepetibles del subconjunto de entrenamiento. La praxis técnica, en este punto, se topa con su propio límite: un modelo que "aprende demasiado bien" de un fragmento finito termina por perder la capacidad de generalizar sobre el fenómeno que pretende describir.

IV.2 El Punto de Quiebre: Determinación del Ajuste

El diagnóstico consolidado —bajo sesgo, alta varianza, brecha sustancial entre train y validación— no deja lugar a la ambigüedad interpretativa: el modelo base se encuentra en un régimen inequívoco de **overfitting**. El reporte de clasificación sobre validación así lo confirma con crudeza: la clase minoritaria (salto, clase 1) obtiene apenas un **f1-score de 0.41**, con **precisión** y **recall** prácticamente empatados en **0.41** y **0.40** respectivamente. El modelo perdió la generalidad necesaria para reconocer el patrón real detrás del salto de una canción.

Análisis de Varianza y Sesgo por Hiperparámetro (con Intervalos de Confianza)




Fig 1. Curvas de Validación de hiperparámetros numéricos, se observa el punto de inflexión en el que la curva de entrenamiento y la curva de validación divergen, momento en el que la varianza se desprende del sesgo y el modelo sobre aprende. (notebooks/exploration3.ipynb)

IV.3 Regularización

Frente a este diagnóstico, la regularización se entiende sobre la *voluntad de ajuste* del algoritmo. Para esto se aplicó lo siguiente

* artist_frequency := Se utilizó frequency encoding mencionado en sección II y se puede acceder al map de este en [data/mapeo_artistas.json](#)

- **Reducir** el `max_depth` equivale a imponer al árbol una amnesia deliberada: se le prohíbe descender hasta las hojas más profundas y singulares del espacio de decisión, forzándolo a conformarse con fronteras de decisión más generales.
- **Aumentar** el `min_samples_split`, por su parte, es un acto de escepticismo estadístico: el modelo ya no puede dividir un nodo basándose en un puñado anecdótico de observaciones; se le exige una mayor masa de evidencia antes de permitirle tomar una decisión.

Ambas técnicas convergen en un mismo propósito: sacrificar una porción de la capacidad de ajuste sobre lo particular en favor de la capacidad de generalización sobre lo universal.

Los resultados numéricos validan esta praxis: el modelo regularizado exhibe una exactitud en entrenamiento de apenas 79.33%, un descenso brutal respecto al 93.83% original, pero una exactitud en validación que se mantiene estable en 78.10%. **La brecha entre ambos conjuntos se contrae de 15.73pp a un residual 1.23pp**. Este es, precisamente, el "ajuste aceptable" (fitting) que se reporta en la consola: el modelo ya no memoriza, ahora *comprende*, aunque sea de manera imperfecta, la estructura subyacente del comportamiento del oyente.




Fig 2. Árbol de decisión final, se observan las restricciones ya impuestas en profundidad y robustez del modelo

IV.4 Búsqueda de Hiper Parámetros:

La determinación de los hiperparámetros óptimos (`max_depth=4`, `min_samples_split=7`, `n_estimators=75`, `criterion='entropy'`) no fue producto del azar, sino de una praxis metodológica en dos momentos complementarios.

En un primer momento, el `RandomizedSearchCV` desempeñó una función exploratoria: ante la imposibilidad computacional de recorrer exhaustivamente el universo combinatorio de hiperparámetros, se optó por un muestreo estocástico para la amplitud del reconocimiento sobre la profundidad, orientando la búsqueda —explícitamente— hacia la maximización del *recall* de la clase minoritaria, la variable que verdaderamente importa en un problema donde el desbalance de clases castiga el reconocimiento del evento raro (el salto). Específicamente se encontraron los mejores rangos para los hiperparametros numéricos y además la elección de `criterion='entropy'` sobre el índice Gini, dado que en el contexto de un desbalance de clases pronunciado, tiende a ser más sensible a las particiones que aíslan a la clase minoritaria.

* `artist_frequency` := Se utilizó `frequency encoding` mencionado en sección II y se puede acceder al map de este en [data/mapeo_artistas.json](#)

En un segundo momento, el `GridSearchCV` operó como contrapunto exhaustivo: una vez acotada la región prometedora del espacio de hiperparámetros por la fase estocástica, la búsqueda en rejilla permitió refinar con precisión quirúrgica la combinación ganadora. Esta secuencia, de lo estocástico a lo exhaustivo, ayudó a definir los mejores parámetros para regularizar el modelo.

Python

```
--- FASE 2: BÚSQUEDA EXHAUSTIVA (GridSearchCV) ---
```

```
TOP 5 MODELOS DEFINITIVOS (GridSearchCV) ORDENADOS POR RECALL:
```

```
-----  
Puesto #1:
```

```
  Parámetros : {'criterion': 'entropy', 'max_depth': 4, 'max_features': None,  
'min_samples_split': 8, 'n_estimators': 75}  
  Recall      : 61.13%  
  Accuracy    : 79.03%
```

```
Puesto #1:
```

```
  Parámetros : {'criterion': 'entropy', 'max_depth': 4, 'max_features': None,  
'min_samples_split': 8, 'n_estimators': 125}  
  Recall      : 61.13%  
  Accuracy    : 79.10%
```

```
Puesto #1:
```

```
  Parámetros : {'criterion': 'entropy', 'max_depth': 4, 'max_features': None,  
'min_samples_split': 7, 'n_estimators': 125}  
  Recall      : 61.13%  
  Accuracy    : 79.10%
```

```
Puesto #1:
```

```
  Parámetros : {'criterion': 'entropy', 'max_depth': 4, 'max_features': None,  
'min_samples_split': 9, 'n_estimators': 75}  
  Recall      : 61.13%  
  Accuracy    : 79.03%
```

```
Puesto #1:
```

```
  Parámetros : {'criterion': 'entropy', 'max_depth': 4, 'max_features': None,  
'min_samples_split': 7, 'n_estimators': 75}  
  Recall      : 61.13%  
  Accuracy    : 79.03%
```

Output 1. GridSearchCV, se imprimieron los 5 mejores modelos ordenados por recall y finalmente se seleccionaron los hiperparametros del primero. (notebooks/exploration3.ipynb)

* `artist_frequency` := Se utilizó frequency encoding mencionado en sección II y se puede acceder al map de este en [data\mapeo_artistas.json](#)

IV.5 Comparación Matricial: La Emancipación Parcial de la Clase Minoritaria

El contraste entre las matrices de confusión del conjunto de prueba constituye la evidencia más contundente de la eficacia de la regularización, en términos de justicia predictiva a ambas clases, sin dejarse llevar por el sesgo del desbalance de clases.

El modelo base, en su matriz, ignora **FN = 161** saltos reales, reconociendo correctamente apenas 133. El modelo regularizado, en cambio, **reduce los FN a 107** y eleva los **TP = 187** —una ganancia neta de 54 saltos adicionales correctamente detectados, equivalente a un **incremento del recall de la clase 1 de 45.2% a 63.6%**. Esta mejora no es gratuita: se paga con un incremento de 73 falsos positivos (de 153 a 226), es decir, el modelo regularizado se vuelve más "suspica", dispuesto a señalar más falsas alarmas de salto a cambio de dejar escapar menos saltos reales. La precisión de la clase minoritaria se mantiene prácticamente estable (46.5% → 45.3%), lo cual revela que la ganancia en recall no fue comprada mediante una degradación proporcional de la confiabilidad de las predicciones positivas, sino mediante una redistribución más justa del umbral de decisión entre ambas clases. La regularización, en suma, no solo domesticó la varianza: equilibró la atención estructural del algoritmo hacia el evento que, siendo minoritario en frecuencia, es mayoritario en relevancia práctica del objetivo.

```
Python
[Modelo Base]
Matriz:
[[1142  153]
 [ 161  133]]

[Modelo Regularizado - Optimizado]
Matriz:
[[1069  226]
 [ 107  187]]
```

Output 2. Matrices de confusión, se imprimieron ambas matrices de confusión y sus métricas para comparar entre el modelo base y el regularizado. (exploration3.py)

IV. Conclusión

El proceso de regularización no fue un mero ejercicio de ajuste paramétrico, sino una corrección sobre la tendencia natural del Random Forest a confundir memorización con conocimiento.

El modelo original, pese a su elevada exactitud aparente, era una hipótesis fraudulenta: aprendía de memoria el entrenamiento y fracasaba al enfrentarse a la clase minoritaria, aquella que —paradójicamente— encierra el verdadero valor predictivo del problema planteado. Al

* artist_frequency := Se utilizó frequency encoding mencionado en sección II y se puede acceder al map de este en [data\mapeo_artistas.json](#)

someter al algoritmo a las restricciones de `max_depth=4` y `min_samples_split=7`, y al depurar su búsqueda de hiperparámetros mediante la dialéctica entre exploración estocástica y refinamiento exhaustivo, logré mitigar el sesgo original sin sacrificar la capacidad de generalización, alcanzando una convergencia notable entre el desempeño en entrenamiento y en validación (**79.33% vs 78.10%**). Más importante aún, conseguí una emancipación parcial de la clase minoritaria frente a la hegemonía numérica de la clase mayoritaria: el recall de los saltos ascendió de **45.2% a 63.6%**, permitiendo que el modelo reconozca —aunque todavía de manera imperfecta— casi dos de cada tres saltos reales, en lugar de menos de la mitad como ocurría bajo el régimen sobreajustado original.

El modelo regularizado no es un modelo perfecto, pero sí es un modelo honesto: uno que ha aprendido a generalizar en lugar de memorizar, y que ha comenzado a hacerle justicia estadística al fenómeno minoritario que, en última instancia, es el que verdaderamente importa comprender.

* `artist_frequency` := Se utilizó frequency encoding mencionado en sección II y se puede acceder al map de este en [data\mapeo_artistas.json](#)