

Instituto Tecnológico de Estudios Superiores de Monterrey
Campus Estado de México

Inteligencia artificial avanzada para la ciencia de datos

Momento de Retroalimentación: Módulo 2 Implementación de una técnica de aprendizaje
máquina sin el uso de un framework. (Portafolio Implementación)

Reporte de Implementación: Árbol de Decisión CART Orientado a Objetos

David Tinoco Romero - A01801491

Reporte de Implementación: Árbol de Decisión CART Orientado a Objetos

Repositorio: [Momento-de-Retroalimentaci-n](#)

Visualización Árbol de decisión:  Lucidchart

I. Definición del Objetivo

Hipótesis Inicial: El modelo será capaz de predecir si una canción será saltada, **y = skipped**, basándose en el contexto temporal de la reproducción (*hour*, *day_of_week*), el entorno tecnológico (*platform_ios*, *platform_osx*), la motivación de inicio (*reason_start_**) y el nivel de preferencia hacia el artista (*artist_frequency**).

II. Dataset

El algoritmo se alimentó con el historial de reproducción de Spotify del año 2026, el cual consta inicialmente de 10,589 registros.

Para garantizar que el modelo realmente aprenda a predecir y no se limite a hacer trampa, se realizó una limpieza estricta de las variables:

- **Para evitar Fuga de Datos (Data Leakage):** Se eliminaron variables como el tiempo reproducido (*ms_played*) y el motivo por el que terminó la canción (*reason_end*).
 - Incluirlos le habría dado al algoritmo la respuesta de si la canción fue saltada antes de hacer la predicción.
- **Para eliminar ruido y datos inútiles:** Se quitaron columnas como *incognito_mode* y *shuffle* porque casi todos sus valores eran exactamente iguales (ceros) y no aportaban capacidad predictiva. También se borró la basura del dataset, como direcciones IP y registros de audiolibros que alteraban el conteo de canciones.

La separación de datos se hizo de manera estratificada, se forzó al sistema a mantener el mismo porcentaje de canciones *skipped* tanto en el grupo de entrenamiento como en el de prueba, asegurando así una evaluación justa frente al desbalance natural de los datos.

III. Análisis de resultados

Al evaluar el Árbol de Decisión con el conjunto de prueba (2,118 canciones nuevas para el modelo), se obtuvo una exactitud (Accuracy =83%). Esto significa que el algoritmo fue capaz de predecir correctamente el destino de 8 de cada 10 canciones. Sin embargo, para entender el comportamiento real del modelo, es necesario analizar la matriz de confusión a detalle.


Matriz de Confusión y Métricas - Desglose por Clases

- **Clase 0 (Canciones Escuchadas):** El modelo es excepcionalmente bueno identificando las canciones que no voy a saltar. Logró un Recall = 97%, lo que indica que logró

* *artist_frequency* := Se utilizó frequency encoding mencionado en sección II y se puede acceder al map de este en [data\mapeo_artistas.json](#)

atrapar casi la totalidad de las canciones escuchadas. Su F1-Score = 90%, confirmando un rendimiento muy sólido y confiable para esta categoría.

- **Clase 1 (Canciones Saltadas):** Aquí se observa un comportamiento más conservador. Debido al desbalance natural de los datos (había 1,726 canciones escuchadas frente a solo 392 saltadas en la prueba), el modelo tuvo dificultades para detectar *todos* los saltos reales, logrando un Recall = 23%. No obstante, cuando el árbol toma la decisión de predecir que una canción será saltada, es bastante seguro de sí mismo: acierta el 63% de las veces (Precision). Su F1-Score = 33%



IV. Conclusión


El desempeño de mi Árbol de Decisión revela las contradicciones predictivas. Aunque la arquitectura matemática implementada converge de manera óptima al alcanzar un accuracy global = 83%, el desglose de mi matriz de confusión evidencia un sesgo algorítmico dictado por el desbalance estructural de las clases originales. El modelo despliega una robustez innegable para identificar las canciones que reproduzco en su totalidad, capturando un *recall* del 97% para la clase mayoritaria; sin embargo, esta misma asimetría sacrifica la sensibilidad técnica

* artist_frequency := Se utilizó frequency encoding mencionado en sección II y se puede acceder al map de este en [data\mapeo_artistas.json](#)

frente a mis decisiones de salto, las cuales quedan parcialmente invisibilizadas con un *recall* de apenas el 23%. Por consiguiente, el algoritmo logra mapear con éxito las fuerzas dominantes de mis hábitos musicales, pero demuestra empíricamente que la optimización de la impureza de Gini resulta insuficiente sin una futura intervención de balanceo de datos para predecir mejor la clase minoritaria skipped.

V. Anexos

Árbol de decisión: [Lucidchart](#)



* artist_frequency := Se utilizó frequency encoding mencionado en sección II y se puede acceder al map de este en [data\mapeo_artistas.json](#)