



Instituto Tecnológico de Estudios Superiores de Monterrey
Campus Estado de México

Inteligencia artificial avanzada para la ciencia de datos

Módulo 2 Uso de framework o biblioteca de aprendizaje máquina para la implementación de una solución. (Portafolio Implementación)

Reporte de Implementación: Random Forest con uso de framework

David Tinoco Romero - A01801491

Reporte de Implementación: Árbol de Decisión CART Orientado a Objetos

Repositorio: [Momento-de-Retroalimentaci-n](#)

I. Definición del Objetivo

El modelo será capaz de predecir si una canción será saltada, **y = skipped**, basándose en el contexto temporal de la reproducción (*hour*, *day_of_week*), el entorno tecnológico (*platform_ios*, *platform_osx*), la motivación de inicio (*reason_start_**) y el nivel de preferencia hacia el artista (*artist_frequency**).

II. Dataset

El algoritmo se alimentó con el historial de reproducción de Spotify del año 2026, el cual consta inicialmente de 10,589 registros.

Para garantizar que el modelo realmente aprenda a predecir y no se limite a hacer trampa, se realizó una limpieza estricta de las variables:

- **Para evitar Fuga de Datos (Data Leakage):** Se eliminaron variables como el tiempo reproducido (*ms_played*) y el motivo por el que terminó la canción (*reason_end*).
 - Incluirlos le habría dado al algoritmo la respuesta de si la canción fue saltada antes de hacer la predicción.
- **Para eliminar ruido y datos inútiles:** Se quitaron columnas como *incognito_mode* y *shuffle* porque casi todos sus valores eran exactamente iguales (ceros) y no aportaban capacidad predictiva. También se borró la basura del dataset, como direcciones IP y registros de audiolibros que alteraban el conteo de canciones.

La separación de datos se hizo de manera estratificada, dividiendo el dataset en 8,471 muestras para el conjunto de entrenamiento y 2,118 muestras para el conjunto de prueba. Se forzó al sistema a mantener el mismo porcentaje de canciones skipped en ambos grupos (18.53%), asegurando así una evaluación justa frente al desbalance natural de los datos

III. Análisis de resultados

Al evaluar el algoritmo de Random Forest mediante el uso de la biblioteca de aprendizaje automático scikit-learn con el conjunto de prueba (2,118 canciones), se obtuvo una exactitud global (Accuracy) del 80.45%. Para entender el comportamiento real del modelo y cómo maneja el desbalance de clases, es necesario analizar la matriz de confusión a detalle:

Matriz de Confusión y Métricas - Desglose por Clases

- **Clase 0 (Canciones Escuchadas):** El modelo mantiene una gran capacidad para identificar las canciones que no se van a saltar. Logró un Recall = 84% y una precisión

* *artist_frequency* := Se utilizó frequency encoding mencionado en sección II y se puede acceder al map de este en [data/mapeo_artistas.json](#)

(Precision) del 91%, obteniendo un F1-Score general = 88%. Esto confirma un rendimiento sólido para la clase mayoritaria.

- **Clase 1 (Canciones Saltadas):** Gracias a la configuración interna del framework para penalizar y balancear los pesos de las clases, el modelo detectó eficientemente los saltos reales, logrando capturar un Recall del 64%. Aunque la precisión en esta clase es del 48% (lo que indica que el modelo genera algunos falsos positivos al ser más sensible), el F1-Score subió a un 55%, demostrando que el algoritmo aprendió de manera exitosa a identificar los verdaderos patrones de rechazo.

Shell

MATRIZ DE CONFUSIÓN

```
=====
                        Pred 0   Pred 1
Real 0 (no skip)      1454     272
Real 1 (skip)         142      250
=====
```

REPORTE DE CLASIFICACIÓN

```
=====
```

	precision	recall	f1-score	support
Clase 0 (no skip)	0.91	0.84	0.88	1726
Clase 1 (skip)	0.48	0.64	0.55	392
accuracy			0.80	2118
macro avg	0.69	0.74	0.71	2118
weighted avg	0.83	0.80	0.81	2118

TOP 10 FEATURES POR IMPORTANCIA (Gini)

```
=====
```

1. reason_start_trackdone	0.4492	
2. reason_start_clickrow	0.2243	
3. reason_start_fwdbtn	0.1244	
4. master_metadata_album_artist_name	0.0847	
5. hour	0.0305	
6. platform_osx	0.0170	
7. day_of_week	0.0164	
8. reason_start_appload	0.0133	
9. platform_ios	0.0129	
10. reason_start_playbtn	0.0088	

* artist_frequency := Se utilizó frequency encoding mencionado en sección II y se puede acceder al map de este en [data\mapeo_artistas.json](#)

IV. Conclusión


El objetivo del experimento era determinar si el contexto temporal, tecnológico y de preferencia artística contienen suficiente señal predictiva para anticipar la decisión de saltar una canción. El modelo implementado alcanzó una exactitud del 80.45% sobre 2,118 registros de prueba completamente nuevos para el algoritmo.

A diferencia de modelos que ignoran el desbalance natural y se limitan a predecir la clase mayoritaria, la correcta aplicación del framework de Machine Learning permitió ponderar las métricas, logrando identificar exitosamente casi 2 de cada 3 saltos reales (Recall 64%). Este aumento en la detección tiene como costo natural una ligera reducción en la precisión general, lo cual es un intercambio matemático esperado y deseable.

Finalmente, la extracción de métricas del modelo reveló que la principal señal predictiva recae en la motivación de inicio (si la canción fue seleccionada manualmente, pasada con el botón de siguiente, o si se reprodujo sola tras terminar la pista anterior), seguida por la lealtad histórica hacia el artista.

V. Anexos

Árbol de decisión:



* artist_frequency := Se utilizó frequency encoding mencionado en sección II y se puede acceder al map de este en [data\mapeo_artistas.json](#)